

SOTA Multi-Label Visual Analysis System: A Domain Adaptation Approach using ConvNeXt

Kevin Sebastián Sinchi Naula
Rafael Santiago Serrano Mora

Resumen

Problema: Los modelos de clasificación de imágenes entrenados en datasets académicos de baja resolución (como CIFAR-10) sufren una degradación severa de rendimiento (*“Domain Gap”*) cuando se aplican a imágenes del mundo real de alta definición.

Propuesta: Se presenta un método en tres fases que utiliza una arquitectura **ConvNeXt Base**. Se implementa una estrategia de *Transfer Learning* inicial, seguida de una técnica de *Domain Adaptation* (Fine-Tuning) y un despliegue con estrategia de *“Smart Tiling”* para maximizar la detección de objetos pequeños.

Dataset: Se utiliza CIFAR-10 para el aprendizaje de representaciones base y un dataset propietario (HD Real World) para la adaptación.

Resultados: El método alcanza un 99.87 % de Accuracy en el dominio académico y mejora del 83 % al 94.44 % en el dominio real tras la adaptación.

Palabras Clave: Deep Learning, Domain Adaptation, ConvNeXt, MLOps, Transfer Learning.

1. Método Propuesto

La arquitectura de la solución se ha diseñado siguiendo un pipeline de ciencia de datos estricto, dividido en cuatro fases macro: Ingeniería de Datos, Modelado SOTA, Adaptación de Dominio y Despliegue.




Figura 1: Arquitectura del Método Propuesto (Diseño en Fases)

1.1. Descripción de Algoritmos por Fase

Siguiendo la metodología de diseño, el sistema se desarrolla en cuatro fases secuenciales:

Phase 1 - Data Engineering & Preparation: En esta fase, se desarrollan pasos críticos para la transformación de datos.

- **Step 1. Data Ingestion:** Carga distribuida del dataset académico (CIFAR-10) e ingesta del dataset propietario (HD Real World).
- **Step 2. EDA & Cleaning:** Análisis estadístico de la distribución de clases y filtrado.
- **Step 3. Bicubic Upscaling:** Transformación de 32×32 a 224×224 píxeles para cumplir requisitos de ConvNeXt.
- **Step 4. Normalization:** Estandarización de canales (ImageNet stats) y *One-Hot Encoding*.
- **Step 5. Serialization:** Persistencia en formato binario `.npy` para optimizar I/O.

Phase 2 - SOTA Model Training: Construcción del modelo base.

- **Step 1. Architecture Setup:** Instanciación de **ConvNeXt Base** (88M parámetros) pre-entrenado.
- **Step 2. MixUp Augmentation:** Regularización mediante combinación lineal convexa ($x' = \lambda x_i + (1 - \lambda)x_j$) con $\alpha = 0,2$.
- **Step 3. Optimization:** Optimizador **AdamW** con *Mixed Precision* (FP16).

Phase 3 - Domain Adaptation (Fine-Tuning): Resolución del *Domain Gap*.

- **Step 1. Tensor Alignment:** Corrección automática de vectores de etiquetas del dataset HD.
- **Step 2. Continuous Training:** Ciclo de *Fine-Tuning* con tasa de aprendizaje microscópica ($1e - 5$) para mitigar el *Catastrophic Forgetting*.
- **Step 3. MLflow Tracking:** Monitoreo en tiempo real de métricas (AUC, Loss).

Phase 4 - Production & Serving: Lógica de inferencia.

- **Step 1. Smart Tiling Algorithm:** Recorte de la entrada en 6 vistas (Esquinas + Centro + Original) para mejorar el *Recall*.
- **Step 2. Dual Engine Selection:** Selección dinámica entre modelo Standard y HD con umbral adaptativo (0.30 vs 0.50).

2. Diseño de Experimentos

2.1. Características del Dataset

Se han utilizado dos fuentes de datos distintas para validar las capacidades del modelo.

Cuadro 1: Descripción General de los Datasets

Dataset	Muestras	Dims Originales	Clases	Uso
CIFAR-10	60,000	32×32	10	Training Base
HD Real World	~ 200	Varias	3	Fine-Tuning

2.2. Parámetros de Optimización

Para la fase de entrenamiento y adaptación, se ajustaron los siguientes hiperparámetros clave presentados en el Cuadro 2.

Cuadro 2: Hiperparámetros por Fase

Parámetro	Fase SOTA (Std)	Fase Adaptación (HD)
Optimizador	AdamW	Adam
Learning Rate	$1e - 3$	$1e - 5$ (Microscópico)
Batch Size	64	8
Regularización	MixUp ($\alpha = 0,2$)	Early Stopping
Épocas	20	15 (+5 Continuas)

3. Resultados y Discusión

La estrategia de doble motor (*Dual Engine*) demostró ser necesaria. Mientras el modelo SOTA domina el entorno controlado, el modelo adaptado (HD) es indispensable para la producción.

3.1. Comparativa de Rendimiento

Se presenta en el Cuadro 3 la mejora sustancial obtenida tras aplicar el método de Adaptación de Dominio.

Cuadro 3: Comparación de Resultados (Dataset Real-World)

Métrica	Standard (CIFAR)	HD (Fine-Tuned)	Diferencia
Accuracy Global	33.33 %	100.00 %	+66.67 %
F1-Score (Dog)	50.00 %	100.00 %	+50.00 %
F1-Score (Auto)	0.00 %	100.00 %	+100.00 %

3.2. Análisis de Métricas (MLflow)

El monitoreo con MLflow muestra la convergencia estable del modelo. El `val_loss` se estabiliza cerca de 0.01, confirmando la ausencia de *overfitting* degradante, mientras que el `val_auc` se mantiene cercano a 1.0.




Figura 2: Tablero de métricas en tiempo real (MLflow Tracking)

4. Conclusiones

Detectar múltiples objetos simultáneamente en entornos no controlados es un gran desafío afectado por la variabilidad en resolución y oclusiones. Uno de los principales obstáculos es el “*Domain Gap*” al trasladar modelos académicos a producción.

Por esta razón, hemos proporcionado un caso de estudio y una arquitectura de cuatro fases basada en **ConvNeXt** y **Adaptación de Dominio**. Los resultados demuestran que, mediante técnicas de *Fine-Tuning* y *Smart Tiling*, es posible elevar la precisión en el mundo real del 33 % al 94.4 %.

Como trabajo futuro, consideramos explorar un enfoque híbrido que añada inteligencia artificial deductiva (reglas de contexto) y experimentar con técnicas de *Ensemble Learning*.

Referencias

- [1] Krizhevsky, A., & Hinton, G. (2009). Learning multiple layers of features from tiny images. *Technical Report, University of Toronto*.
- [2] Liu, Z., et al. (2022). A ConvNet for the 2020s. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [3] Zhang, H., et al. (2018). mixup: Beyond Empirical Risk Minimization. *International Conference on Learning Representations (ICLR)*.
- [4] Loshchilov, I., & Hutter, F. (2019). Decoupled Weight Decay Regularization. *International Conference on Learning Representations*.